

Laporan Praktikum Minggu Ke-4 Kontrol Cerdas

Minggu ke-4

Nama : Syahda Nur Wijaya

NIM : 224308071

Kelas : TKA 7C

Akun Github (Tautan): <https://github.com/syahdanurwijaya>

1. Judul Percobaan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

Tujuan dari percobaan ini, sebagai berikut:

- a. Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
- b. Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
- c. Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
- d. Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
- e. Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

Reinforcement Learning adalah metode pembelajaran mesin di mana agen belajar mengambil keputusan secara sekuensial dengan cara berinteraksi dengan lingkungan, menerima umpan balik berupa reward, dan mengoptimalkan tindakannya untuk memaksimalkan nilai total reward yang diperoleh. Reinforcement Learning (RL) bekerja melalui kerangka Markov Decision Processes (MDP) (Febrian dkk., t.t.). MDP merupakan fungsi matematis yang memodelkan permasalahan pengambilan keputusan secara sekuensial. Deretan sekuensial yang diperlukan MDP diperoleh melalui hasil

interaksi agent dengan lingkungan secara kontinu. Proses interaksi dimulai dari agent yang mempunyai kemampuan persepsi untuk menerima informasi dari lingkungan, lalu melakukan serangkaian aksi dan mendapatkan timbal balik berupa reward. Dalam setiap literasinya, agent akan mempelajari lingkungan dan mengoptimalkan aksi selanjutnya untuk mendapatkan nilai reward yang maksimal.

Salah satu algoritma RL yang populer adalah Deep Q-Network (DQN), yang mengkombinasikan Q-learning dengan jaringan saraf dalam (Deep Neural Networks) untuk mengaproksimasi fungsi nilai aksi. DQN memungkinkan agen melakukan pembelajaran dari pengalaman masa lalu yang disimpan dalam memori replay, dengan strategi eksplorasi dan eksploitasi yang seimbang melalui parameter epsilon-greedy. Dalam praktikum ini, agen DQN diterapkan pada environment simulasi CartPole menggunakan pustaka OpenAI Gym, yang bertujuan mengendalikan tiang pada kereta supaya tetap seimbang tanpa jatuh.

Implementasi praktikum melibatkan pembuatan model jaringan saraf dengan beberapa lapisan Dense dan fungsi aktivasi ReLU, optimasi menggunakan Adam optimizer, serta proses pelatihan menggunakan data replay yang diambil secara acak untuk meningkatkan stabilitas pembelajaran. Evaluasi kinerja agen dilakukan dengan pengujian di environment simulasi dan analisis dampak perubahan parameter seperti faktor diskonto (γ), tingkat eksplorasi (epsilon), dan laju pembelajaran.

4. Analisis dan Diskusi

➤ Analisis

a. Performa Agen dalam Mengontrol CartPole

Agen DQN dapat belajar mengendalikan environment CartPole dengan cukup baik. Seiring bertambahnya episode pelatihan, agen meningkatkan kemampuan menyeimbangkan tiang sehingga bertahan lebih lama, dibuktikan dari nilai total reward yang meningkat. Hal ini karena agen belajar dari pengalaman dan memperbarui nilai Q untuk

memilih aksi optimal. Namun, performa tergantung pada parameter yang dipilih dan ketersediaan pengalaman yang cukup.

- b. Pengaruh Perubahan Parameter (Gamma, Epsilon, Learning Rate)
 - Gamma (discount factor) menentukan nilai pentingnya reward jangka panjang. Gamma tinggi (dekat 1) membuat agen fokus pada hasil masa depan, memperbaiki kestabilan belajar jangka panjang, tapi bisa memperlambat konvergensi.
 - Epsilon mengatur trade-off eksplorasi vs eksploitasi. Epsilon tinggi meningkatkan eksplorasi yang berguna di awal agar agen mencoba berbagai tindakan. Pengurangan epsilon secara perlahan (decay) penting agar agen beralih ke eksploitasi hasil belajar.
 - Learning rate mengontrol seberapa besar pembaruan bobot jaringan. Learning rate terlalu besar bisa membuat pelatihan tidak stabil, terlalu kecil membuat belajar lambat.

c. Tantangan Selama Pelatihan Agen RL

Tantangan umum meliputi instabilitas pelatihan akibat korelasi data, sulitnya eksplorasi di ruang tindakan besar, dan kompleksitas reward shaping agar agen belajar dengan baik. Selain itu, agen kadang terjebak dalam local optimum karena kurang eksplorasi, dan parameter yang tidak optimal bisa menyebabkan agen gagal belajar efektif.

➤ **Diskusi**

a. Perbedaan RL dengan Supervised Learning dalam Sistem Kendali

RL belajar berdasarkan interaksi langsung dengan lingkungan dan umpan balik reward, tanpa label output yang eksplisit seperti supervised learning. RL fokus pada pengambilan tindakan sekuensial yang mempengaruhi keadaan selanjutnya, sedangkan supervised learning belajar dari data statis label input-output. Dalam sistem kendali, RL lebih cocok untuk sistem dinamis dan kompleks tanpa model eksplisit.

b. Optimasi Strategi Eksplorasi dan Eksploitasi

Eksplorasi dan eksploitasi dapat dioptimalkan dengan pendekatan seperti decay epsilon secara adaptif, menggunakan strategi seperti epsilon-greedy, softmax, atau metode lain seperti UCB. Prioritized

experience replay juga meningkatkan efisiensi belajar dengan memilih pengalaman penting. Teknik seperti target network dan double DQN juga membantu stabilisasi pelatihan dan mengurangi bias.

c. Potensi Aplikasi RL dalam Sistem Kendali Nyata



RL banyak diterapkan pada kendali robotika (navigasi dan manipulasi), kendaraan otonom (path planning dan pengambilan keputusan), optimasi proses industri, pengelolaan energi (smart grid), dan sistem cerdas lainnya yang memerlukan kendali adaptif dan pengambilan keputusan secara real-time dalam lingkungan dinamis.

5. Assignment

Pada praktikum ini melatih pemahaman konsep dasar RL dan implementasi DQN untuk kendali otonom, termasuk eksperimen serta analisis performa model dalam simulasi lingkungan dinamis. Praktikum ini mengeksplorasi penerapan Reinforcement Learning khususnya Deep Q-Network (DQN) untuk mengontrol sistem kendali otonom dalam environment simulasi CartPole dan MountainCar. Agen DQN menggunakan jaringan saraf tiruan untuk mengaproksimasi fungsi nilai aksinya dan belajar melalui interaksi trial-error dalam lingkungan.

Hasil praktikum menunjukkan kemampuan agen untuk belajar mempertahankan keseimbangan tiang CartPole dalam durasi waktu yang panjang, dengan performa yang terus meningkat seiring pelatihan. Parameter penting seperti gamma, epsilon, dan learning rate berperan kuat dalam stabilitas dan efektivitas pembelajaran. Gamma tinggi memungkinkan agen fokus pada reward jangka panjang, sementara decay epsilon mengatur strategi eksplorasi secara adaptif agar tidak stagnan. Learning rate harus disesuaikan untuk menghindari pelatihan yang tidak stabil.

6. Data dan Output Hasil Pengamatan

No	Variable	CartPole-v1	MountainCar-v0
1.	Waktu Pelatihan	Pada CartPole-v1 relatif cepat mencapai performa yang lebih baik dalam beberapa ratus episode.	Pada MountainCar-v0 membutuhkan banyak episode agar lebih stabil.
2.	Jumlah Episode	Ditraining 1000 episode <pre>agent = DQNAgent(state_size, action_size) episodes = 1000 batch_size = 32</pre>	Ditraining 1000 episode <pre>agent = DQNAgent(state_size, action_size) episodes = 1000 batch_size = 32</pre>
3.	Skor per Episode (Testing)	Skor Rata rata meningkat signifikan (contoh: 8,9,10 hingga >200)	Skor awal mencapai 199 karena maksimal langkah dalam satu episode 200
4.	Kinerja Agen	Agen semakin stabil dengan skor yang makin tinggi.	Agen masih menghadapi tantangan untuk mencapai puncak bukit
5.	Kondisi Berhasil	Episode berakhir jika tiang jatuh atau batas langkah maksimum tercapai.	Episode berakhir jika mobil berhasil sampai puncak bukit (flag).
6.	Output		

7. Kesimpulan

Pada praktikum kali ini berhasil membuat implementasi dasar Deep Q-Network (DQN), sebuah algoritma *value-based* dalam Reinforcement Learning (RL), untuk melatih agen agar mencapai tujuan dalam lingkungan simulasi (misalnya CartPole-v1 atau MountainCar-v0). Parameter utama seperti gamma, epsilon, dan learning rate sangat mempengaruhi kestabilan dan kecepatan pembelajaran. Tantangan utamanya adalah menjaga

keseimbangan eksplorasi dan eksploitasi serta stabilitas pelatihan jaringan saraf.

8. Saran

Menerapkan teknik target network untuk mengurangi ketidakstabilan pelatihan dan overestimation pada nilai Q. Hal ini dapat membantu model konvergen lebih stabil dan cepat. Serta menggunakan prioritized experience replay agar agen lebih fokus belajar dari pengalaman penting yang berdampak besar pada pembaruan jaringan. Transfer learning dari model yang telah dilatih di lingkungan serupa dapat mempercepat proses konvergensi

9. Daftar Pustaka

Febrian, R., Setiawan, E., & Prasetyo, B. H. (t.t.). *Simulasi Metode Dueling Double Deep Q-Learning pada Unmanned Aerial Vehicle untuk Menghindari Halangan.*